

Sistema Inteligente de Contagem de Parafusos Visão Computacional Clássica para Apoio ao Processo de Picking

Nara Raquel Dias Andrade

¹ Bootcamp de Ciência de Dados e Inteligência Artificial
Desafio Técnico - Contagem Automática de Parafusos
Picos - PI - Brasil

diasnara430@gmail.com

Abstract. *Manual counting of components in industrial and logistics processes is prone to human errors, particularly under time constraints and large inventory volumes. In this context, this work presents the development of an automatic screw counting system based on Classical Computer Vision techniques. The proposed solution was designed considering low computational cost, interpretability, and the possibility of execution on mobile devices, avoiding the use of Deep Learning models due to the limited availability of training data. The method combines Otsu automatic thresholding, morphological operations, contour analysis, geometric filtering, and adaptive Watershed segmentation to handle groups of overlapping screws. In addition to the core algorithm, an interactive web application was developed using Streamlit to demonstrate the solution. Experiments conducted on the dataset provided by the challenge achieved 100% counting accuracy, demonstrating the effectiveness of the proposed approach. .*

Resumo. *A contagem manual de componentes em processos logísticos e industriais é uma atividade suscetível a erros humanos, especialmente quando realizada sob restrições de tempo e em ambientes com grande volume de itens. Nesse contexto, este trabalho apresenta o desenvolvimento de um sistema automático para contagem de parafusos utilizando técnicas de Visão Computacional Clássica. A solução proposta foi concebida considerando restrições de baixo custo computacional, interpretabilidade e possibilidade de execução em dispositivos móveis, descartando o uso de modelos de Aprendizado Profundo devido à limitada disponibilidade de dados para treinamento. O método desenvolvido combina binarização automática por Otsu, operações morfológicas, análise de contornos, filtros geométricos e segmentação adaptativa baseada em Watershed para lidar com agrupamentos de parafusos. Além do algoritmo principal, foi desenvolvida uma aplicação web interativa utilizando Streamlit para demonstração da solução. Os experimentos realizados sobre o conjunto de imagens fornecido pelo desafio obtiveram 100% de acerto na contagem dos objetos, demonstrando a viabilidade da abordagem proposta.*

1. Introdução

A transformação digital impulsionada pelos conceitos da Indústria 4.0 tem ampliado significativamente a adoção de sistemas inteligentes voltados à automação de processos industriais e logísticos. Entre as diversas atividades passíveis de automação, destaca-se o processo de picking, responsável pela separação e conferência de itens em operações de armazenamento, distribuição e montagem. Embora muitas etapas desses processos já contem com elevado grau de automação, a contagem de pequenos componentes ainda é frequentemente realizada manualmente. Essa atividade, apesar de aparentemente simples, está sujeita a falhas decorrentes de fadiga operacional, distrações, limitações de tempo e variabilidade humana. Em ambientes de produção com grande volume de itens, erros de contagem podem resultar em perdas financeiras, retrabalho, atrasos operacionais e inconsistências de estoque.

Dentre os componentes frequentemente manipulados em processos de picking encontram-se os parafusos, elementos mecânicos amplamente utilizados em atividades de montagem industrial. A automatização da contagem desses objetos representa uma oportunidade relevante para redução de custos operacionais e aumento da confiabilidade dos processos. Neste contexto, o presente trabalho apresenta o desenvolvimento de um sistema inteligente para contagem automática de parafusos a partir de imagens digitais. Diferentemente de abordagens baseadas em Aprendizado Profundo, que normalmente demandam grandes volumes de dados rotulados para treinamento, optou-se pela utilização de técnicas de Visão Computacional Clássica. Essa escolha foi motivada principalmente pela limitada quantidade de imagens disponibilizadas pelo desafio, bem como pela necessidade de construção de uma solução leve, interpretável e compatível com dispositivos móveis.

A solução proposta combina técnicas de pré-processamento de imagens, segmentação automática, operações morfológicas, análise geométrica de contornos e segmentação adaptativa por Watershed para estimar a quantidade de parafusos presentes em cada imagem. Além disso, foi desenvolvida uma aplicação web interativa para demonstração prática do sistema, permitindo a submissão de imagens e a visualização detalhada das etapas do pipeline de processamento. Os resultados obtidos demonstraram a eficácia da abordagem proposta, alcançando acurácia de 100% sobre o conjunto de imagens disponibilizado pelo desafio e evidenciando o potencial da Visão Computacional Clássica como alternativa viável para problemas de contagem de objetos em cenários com disponibilidade limitada de dados.

2. Entendimento do Problema

O desafio proposto consiste no desenvolvimento de uma solução capaz de realizar a contagem automática de parafusos a partir de imagens digitais, simulando um cenário típico de processos de picking em ambientes industriais e logísticos. Embora o problema possa parecer simples em um primeiro momento, sua resolução envolve diversos desafios relacionados à variabilidade visual dos objetos presentes nas imagens. Entre esses desafios destacam-se diferenças de iluminação, variações de escala, mudanças de orientação dos parafusos, proximidade entre objetos e ocorrência de agrupamentos que dificultam a segmentação individual.

Além dos desafios visuais, o problema apresenta importantes restrições técnicas.

O conjunto disponibilizado para desenvolvimento era composto por apenas cinco imagens, quantidade insuficiente para treinamento adequado de modelos de Aprendizado Profundo. Em cenários com tão poucos exemplos, modelos neurais tendem a apresentar elevado risco de sobreajuste (overfitting), aprendendo características específicas das imagens de treinamento sem desenvolver capacidade de generalização. Outro requisito importante do desafio consistia na possibilidade de execução da solução em dispositivos móveis, como smartphones utilizados por operadores durante atividades de separação e conferência de itens. Essa restrição impõe limitações relacionadas ao consumo de memória, capacidade de processamento e tempo de resposta da aplicação.

Diante dessas características, definiu-se como objetivo principal o desenvolvimento de uma solução baseada em Visão Computacional Clássica, capaz de operar sem treinamento prévio, com baixo custo computacional e elevada interpretabilidade. A estratégia adotada buscou explorar propriedades geométricas intrínsecas dos parafusos, tais como área, formato, razão de aspecto e compacidade, combinadas com técnicas clássicas de segmentação de imagens.

A Figura 1 apresenta as imagens utilizadas durante o desenvolvimento e validação da solução proposta.




Figura 1. Conjunto de imagens disponibilizado para o desenvolvimento e validação da solução proposta.

3. Fundamentação Teórica

3.1. Visão Computacional Clássica versus Aprendizado Profundo

Atualmente, problemas de detecção e contagem de objetos são frequentemente resolvidos por meio de técnicas de Aprendizado Profundo, especialmente utilizando arquiteturas como YOLO, Faster R-CNN e Mask R-CNN. Essas abordagens apresentam elevado desempenho quando treinadas sobre grandes volumes de dados rotulados, permitindo a aprendizagem automática de características visuais complexas. Entretanto, o sucesso dessas técnicas depende diretamente da disponibilidade de conjuntos de dados suficientemente representativos. Em cenários com poucas amostras, o treinamento de modelos neurais tende a resultar em sobreajuste, reduzindo significativamente sua capacidade de generalização.

Considerando que o desafio disponibilizou apenas cinco imagens para desenvolvimento da solução, optou-se pela utilização de técnicas de Visão Computacional Clássica. Diferentemente das abordagens baseadas em aprendizado, os métodos clássicos utilizam propriedades matemáticas e geométricas diretamente extraídas das imagens, dispensando etapas de treinamento e reduzindo consideravelmente o custo computacional da solução. Além disso, técnicas clássicas oferecem elevada interpretabilidade, permitindo compreender de forma explícita quais critérios estão sendo utilizados para identificar os objetos de interesse. Essa característica é particularmente importante em aplicações industriais, nas quais transparência e rastreabilidade das decisões constituem requisitos desejáveis.

A Tabela 1 apresenta uma comparação resumida entre as duas abordagens.

Tabela 1. Comparação entre Visão Computacional Clássica e Aprendizado Profundo.

Critério	Visão Clássica	Deep Learning
Necessidade de treinamento	Não	Sim
Quantidade de dados	Baixa	Alta
Interpretabilidade	Alta	Baixa
Custo computacional	Baixo	Elevado
Execução em smartphones	Favorável	Limitada

Considerando simultaneamente a pequena quantidade de dados disponíveis, a necessidade de interpretabilidade e a exigência de execução em dispositivos móveis, concluiu-se que a Visão Computacional Clássica representava a alternativa mais adequada para o problema proposto.

3.2. Binarização Automática pelo Método de Otsu

A segmentação de imagens representa uma das etapas mais importantes em sistemas de Visão Computacional, pois determina a separação entre objetos de interesse e o fundo da cena. Neste trabalho foi utilizado o método de Otsu, uma técnica de limiarização automática baseada na maximização da variância entre classes. O algoritmo busca determinar automaticamente o valor de limiar que melhor separa os pixels pertencentes ao objeto daqueles pertencentes ao fundo.

A principal vantagem dessa abordagem é a eliminação da necessidade de ajuste manual de parâmetros para cada imagem analisada. Como as imagens do desafio apresentam pequenas variações de iluminação e contraste, a utilização de um limiar fixo poderia comprometer a robustez da solução. Durante os experimentos observou-se que os parafusos apresentavam intensidade média inferior à do fundo. Dessa forma, foi empregada a variante invertida do método (*Threshold Binary Inverted*), permitindo representar os parafusos em branco e o fundo em preto após a segmentação.

A Figura 2 apresenta um exemplo do resultado produzido pela binarização automática.




Figura 2. Exemplo do resultado da binarização automática utilizando o método de Otsu. À esquerda, a imagem original; à direita, a máscara binária gerada automaticamente.

4. Arquitetura da Solução

A solução desenvolvida foi estruturada como um pipeline sequencial de processamento de imagens, no qual cada etapa possui uma função específica na identificação e contagem dos parafusos presentes na cena. O fluxo completo da solução é apresentado na Figura 3. Inicialmente, a imagem capturada é submetida a um processo de redimensionamento para adequação ao ambiente de execução. Em seguida, técnicas de pré-processamento são aplicadas com o objetivo de reduzir ruídos e melhorar a qualidade da segmentação.

Após essa etapa, realiza-se a binarização automática utilizando o método de Otsu, responsável por separar os parafusos do fundo da imagem. A máscara resultante passa então por operações morfológicas destinadas à remoção de pequenos artefatos e ao refinamento das regiões segmentadas.

Posteriormente, são extraídos os contornos dos objetos identificados, sobre os quais são calculadas características geométricas utilizadas para filtragem de falsos positivos. Em situações nas quais múltiplos parafusos aparecem agrupados em uma única região, utiliza-se uma estratégia adaptativa baseada em Watershed para estimar a quanti-

dade de objetos presentes. Por fim, as estimativas obtidas são consolidadas para produzir a contagem final dos parafusos presentes na imagem.




Figura 3. Arquitetura geral da solução proposta

5. Metodologia

5.1. Redimensionamento

A primeira etapa do pipeline consiste no redimensionamento das imagens de entrada. Embora as imagens fornecidas apresentassem resolução suficiente para identificação dos objetos, o processamento em dispositivos móveis impõe restrições relacionadas ao consumo de memória e ao tempo de execução.

Dessa forma, definiu-se um limite máximo de 800 pixels para a maior dimensão da imagem. Quando necessário, as imagens são redimensionadas preservando sua proporção original, evitando deformações que poderiam comprometer as características geométricas dos parafusos. Essa estratégia reduz o custo computacional sem provocar perda significativa de informação visual relevante para o processo de detecção.

5.2. Pré-processamento

Imagens de componentes metálicos frequentemente apresentam reflexos, pequenas variações de iluminação e ruídos decorrentes do processo de captura. Esses fatores podem prejudicar a etapa de segmentação, produzindo regiões fragmentadas ou falsos contornos. Para minimizar esses efeitos foi aplicado um filtro Gaussiano com kernel de tamanho

5×5. Essa técnica realiza uma suavização controlada da imagem, reduzindo ruídos de alta frequência sem comprometer significativamente os limites dos objetos.

Durante os experimentos também foi avaliada a utilização da técnica CLAHE (*Contrast Limited Adaptive Histogram Equalization*), amplamente empregada para realce de contraste local. Entretanto, observou-se que essa abordagem provocava a fusão de regiões do fundo com os objetos em determinadas imagens do conjunto de dados, especialmente em cenários com fundo muito claro. Diante desses resultados, optou-se pela utilização exclusiva do filtro Gaussiano, que apresentou comportamento mais estável e consistente em todas as imagens analisadas.

5.3. Operações Morfológicas

Após a etapa de segmentação, observou-se a presença de pequenas imperfeições na máscara binária gerada pelo método de Otsu. Entre essas imperfeições destacavam-se ruídos isolados, pequenas descontinuidades nos contornos dos parafusos e regiões internas parcialmente fragmentadas.

Para corrigir esses problemas foram empregadas operações morfológicas baseadas em elementos estruturantes elípticos. Inicialmente foi aplicada uma operação de abertura morfológica (*Opening*), responsável por remover pequenas regiões de ruído preservando a estrutura principal dos objetos.

Em seguida foi utilizada uma operação de fechamento morfológico (*Closing*), cujo objetivo foi preencher pequenas lacunas existentes nos contornos dos parafusos e produzir regiões mais homogêneas para a etapa de extração de contornos. Durante os experimentos foram avaliadas operações adicionais de dilatação. Entretanto, verificou-se que dilatações mais agressivas provocavam a fusão de parafusos próximos em um único objeto segmentado, dificultando a contagem correta. Dessa forma, optou-se por uma configuração conservadora composta apenas por abertura e fechamento, que apresentou melhor equilíbrio entre remoção de ruído e preservação dos objetos.

5.4. Extração de Contornos

Após o refinamento da máscara binária, procedeu-se à identificação das regiões candidatas a parafusos por meio da extração de contornos utilizando a função *findContours* da biblioteca OpenCV.

Cada contorno identificado representa uma região conectada da imagem segmentada. Para cada uma dessas regiões foram calculadas características geométricas capazes de descrever quantitativamente sua forma e tamanho. Entre as características extraídas destacam-se:

- Área do contorno;
- Retângulo envolvente (*Bounding Box*);
- Centroide;
- Área do casco convexo (*Convex Hull*);
- Razão de aspecto;
- Solidity;
- Extent.

Essas medidas constituem a base para a etapa seguinte de filtragem geométrica, permitindo diferenciar parafusos de artefatos presentes na imagem.

5.5. Filtragem Geométrica

Nem toda região identificada após a segmentação corresponde necessariamente a um parafuso. Reflexos, sombras, fragmentos de fundo e artefatos gerados pelo processo de binarização podem produzir contornos indesejados. Para minimizar falsos positivos foi desenvolvido um conjunto de filtros geométricos baseado em propriedades observadas empiricamente nas imagens do conjunto de dados.

Inicialmente são descartadas regiões com área muito pequena, tipicamente associadas a ruídos, bem como regiões excessivamente grandes que representam porções do fundo ou agrupamentos inadequadamente segmentados. Em seguida utiliza-se a razão de aspecto calculada por meio do ajuste de uma elipse ao contorno. Essa abordagem foi escolhida em substituição à utilização direta do retângulo envolvente, uma vez que parafusos inclinados podem apresentar *bounding boxes* quase quadradas, enquanto a elipse ajustada preserva melhor sua orientação real.

Além disso, foram empregados critérios baseados em *solidity* e *extent*. A métrica de *solidity* compara a área do objeto com a área de seu casco convexo, enquanto o *extent* relaciona a área do objeto à área de seu retângulo envolvente. Essas medidas permitem eliminar regiões excessivamente irregulares ou incompatíveis com a geometria típica dos parafusos.

Outro filtro importante consistiu na remoção de regiões conectadas às bordas da imagem. Durante os experimentos observou-se que partes do fundo frequentemente apareciam conectadas aos limites da imagem após a binarização, produzindo falsos contornos de grandes dimensões. A eliminação dessas regiões contribuiu significativamente para a robustez da solução.

5.6. Estratégia de Contagem

Após a identificação dos contornos válidos, torna-se necessário estimar quantos parafusos estão representados em cada região detectada. A estratégia adotada baseia-se inicialmente na hipótese de que a maioria dos contornos corresponde a um único parafuso. A partir dessa premissa calcula-se a mediana das áreas dos contornos detectados, que passa a representar uma estimativa robusta da área típica de um parafuso individual.

A utilização da mediana foi escolhida em detrimento da média aritmética por apresentar menor sensibilidade à presença de regiões excepcionalmente grandes, como agrupamentos de múltiplos parafusos. Regiões cuja área apresenta comportamento compatível com a mediana são contabilizadas diretamente como um único objeto. Por outro lado, regiões significativamente maiores são encaminhadas para uma etapa adicional de análise baseada em segmentação adaptativa.

5.7. Tratamento de Sobreposições por Watershed

Um dos principais desafios encontrados durante o desenvolvimento da solução foi a presença de agrupamentos de parafusos muito próximos entre si, produzindo uma única região conectada após a segmentação. Uma estratégia simples baseada apenas na divisão da área total pela área média dos objetos mostrou-se insuficiente, pois não considera a distribuição espacial interna dos componentes agrupados.

Para superar essa limitação foi utilizada uma abordagem baseada na Transformada de Distância combinada ao algoritmo Watershed. Inicialmente calcula-se a distância de

cada pixel interno até a borda mais próxima da região segmentada. Os máximos locais dessa transformada tendem a coincidir com os centros dos objetos presentes no agrupamento.

Em seguida aplica-se um limiar adaptativo sobre a transformada de distância, produzindo marcadores que representam candidatos a centros de parafusos individuais. O número de componentes conectados identificados nessa etapa é utilizado como estimativa da quantidade de objetos presentes no agrupamento. Essa estratégia permitiu tratar adequadamente situações de contato parcial entre parafusos, aumentando significativamente a capacidade de contagem em cenários mais complexos.

5.8. Pipeline Completo

A Figura 4 apresenta a execução completa do pipeline desenvolvido sobre uma das imagens do conjunto de dados.

Inicialmente a imagem original é submetida ao processo de suavização por filtro Gaussiano. Em seguida realiza-se a segmentação automática utilizando o método de Otsu, produzindo uma máscara binária na qual os parafusos são destacados do fundo.

Posteriormente são aplicadas operações morfológicas para remoção de ruídos e refinamento das regiões segmentadas. A máscara resultante é então utilizada para extração dos contornos, aplicação dos filtros geométricos e estimativa da quantidade de parafusos presentes. Observa-se que cada etapa contribui progressivamente para a simplificação da cena e para a identificação robusta dos objetos de interesse.



Figura 4. Pipeline completo de processamento aplicado à Imagem 1.

6. Resultados Experimentais

6.1. Configuração Experimental

Os experimentos foram conduzidos utilizando as cinco imagens disponibilizadas pelo desafio. As imagens apresentam diferentes cenários de contagem, incluindo objetos isolados, objetos parcialmente agrupados e variações de fundo e iluminação. Todas as avaliações foram realizadas utilizando a mesma configuração de parâmetros definida durante o desenvolvimento da solução, sem ajustes específicos para imagens individuais. Essa estratégia permite avaliar a capacidade de generalização do método proposto dentro do conjunto analisado. A validação foi realizada comparando-se a quantidade real de parafusos presentes em cada imagem (*Ground Truth*) com a quantidade estimada pelo sistema.

Tabela 2. Comparação entre valores reais e predições do sistema.

Imagem	Quantidade Real	Quantidade Predita
img1	8	8
img2	1	1
img3	4	4
img4	2	2
img5	10	10

6.2. Resultados Obtidos

A Tabela 2 apresenta os resultados obtidos pelo sistema para cada uma das imagens do conjunto de validação.

Observa-se que a solução foi capaz de reproduzir corretamente a contagem real em todas as imagens analisadas. O desempenho obtido demonstra a eficácia da combinação entre segmentação automática, análise geométrica e tratamento adaptativo de agrupamentos por meio do algoritmo Watershed.

Destaca-se especialmente o desempenho obtido na Imagem 5, considerada a mais desafiadora do conjunto por apresentar múltiplos parafusos em contato parcial, formando agrupamentos complexos. Mesmo nesse cenário, o sistema foi capaz de identificar corretamente a quantidade de objetos presentes.

6.3. Métricas de Avaliação

Para quantificar o desempenho do sistema foram utilizadas métricas amplamente empregadas em problemas de regressão e contagem de objetos.

A Equação 1 apresenta o Erro Absoluto Médio (MAE), responsável por medir o desvio médio entre os valores previstos e os valores reais.

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (1)$$

A Equação 2 apresenta a Raiz do Erro Quadrático Médio (RMSE).

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (2)$$

Além disso, foi calculada a taxa de acerto exata (*Accuracy*), definida como a proporção de imagens cuja contagem foi estimada corretamente.

Os resultados obtidos foram:

- Accuracy: 100
- MAE: 0
- RMSE: 0

Esses valores indicam que não houve diferença entre as contagens estimadas e os valores reais para nenhuma das imagens avaliadas.

6.4. Visualização dos Resultados

A Figura 5 apresenta a saída final produzida pelo sistema para todas as imagens do conjunto de validação.

Os contornos identificados são destacados visualmente, permitindo verificar quais regiões foram consideradas durante o processo de contagem. Nos casos em que múltiplos parafusos foram identificados dentro de uma mesma região, o sistema utiliza anotações específicas para indicar a estimativa produzida pelo mecanismo de segmentação adaptativa.




Figura 5. Resultados finais produzidos pelo sistema para todas as imagens avaliadas.

Observa-se que o sistema foi capaz de identificar corretamente todos os parafusos presentes nas imagens avaliadas, incluindo cenários com objetos isolados (Figura 5b), múltiplos objetos bem separados (Figura 5c) e agrupamentos complexos de parafusos parcialmente sobrepostos (Figura 5e).

7. Aplicação Web

Além do desenvolvimento do algoritmo de contagem, foi criada uma aplicação web interativa utilizando a biblioteca Streamlit com o objetivo de disponibilizar a solução para utilização prática por operadores e avaliadores.

A interface permite que o usuário realize o envio de imagens contendo parafusos por meio do navegador, sem necessidade de instalação de softwares adicionais. Após o

carregamento da imagem, o sistema executa automaticamente todas as etapas do pipeline desenvolvido e apresenta os resultados de forma visual e intuitiva.

Como diferencial, a aplicação não exibe apenas a contagem final dos objetos, mas também permite visualizar as principais etapas do processamento, incluindo a imagem original, a segmentação binária gerada pelo método de Otsu, a máscara após as operações morfológicas e a imagem final anotada com os contornos detectados.

Essa funcionalidade aumenta significativamente a interpretabilidade da solução, permitindo compreender como cada decisão foi produzida pelo sistema.

Outro benefício da aplicação web consiste na facilidade de implantação em diferentes ambientes computacionais. Como o processamento é realizado utilizando técnicas clássicas de Visão Computacional, a solução apresenta baixo consumo de recursos computacionais, tornando viável sua utilização em computadores convencionais e dispositivos de menor capacidade.

As Figuras a seguir apresentam a interface desenvolvida para demonstração da solução. A Figura 6 apresenta a tela inicial da aplicação.




Figura 6. Interface inicial do sistema antes do envio da imagem

A Figura 7 mostra o resultado da contagem. A Figura 8 apresenta as métricas calculadas. A Figura 9 exibe as etapas intermediárias do pipeline.

8. Conclusão

Este trabalho apresentou o desenvolvimento de um sistema inteligente para contagem automática de parafusos utilizando técnicas de Visão Computacional Clássica. A solução foi concebida considerando restrições importantes do problema proposto, especialmente a reduzida quantidade de imagens disponíveis para desenvolvimento e a necessidade de execução em ambientes com recursos computacionais limitados. Em razão dessas características, optou-se pela utilização de técnicas clássicas de processamento de imagens em substituição a abordagens baseadas em Aprendizado Profundo.

O método desenvolvido combinou binarização automática por Otsu, operações morfológicas, análise geométrica de contornos e segmentação adaptativa baseada em Wa-



Figura 7. Resultado visual da contagem apresentado na interface




Figura 8. Métricas apresentadas sobre o processamento

tershed para tratamento de agrupamentos de objetos. A integração dessas técnicas permitiu construir uma solução robusta, interpretável e computacionalmente eficiente. Os experimentos realizados demonstraram elevado desempenho da abordagem proposta, obtendo 100% de acerto sobre o conjunto de validação, com erro absoluto médio (MAE) igual a zero e raiz do erro quadrático médio (RMSE) também igual a zero. Como contribuição adicional, foi desenvolvida uma aplicação web interativa utilizando Streamlit, permitindo a utilização prática do sistema por meio de uma interface simples e intuitiva.

Apesar dos resultados obtidos, algumas limitações devem ser consideradas. O conjunto de dados utilizado possui tamanho reduzido e apresenta baixa diversidade visual quando comparado a cenários industriais reais. Em ambientes com grande variabilidade de iluminação, múltiplos tipos de parafusos ou altos níveis de oclusão, ajustes adicionais podem ser necessários.

Como trabalhos futuros, sugere-se a expansão do conjunto de dados, a realização




Figura 9. Visualização intermediária das etapas do algoritmo até a conclusão

de testes em cenários industriais reais e a investigação de abordagens híbridas combinando Visão Computacional Clássica com técnicas de Aprendizado de Máquina para aumento da robustez e capacidade de generalização do sistema. Os resultados obtidos demonstram que técnicas clássicas de processamento de imagens permanecem altamente relevantes para problemas de contagem de objetos quando aplicadas de forma criteriosa e fundamentada, constituindo uma alternativa eficiente, interpretável e de baixo custo computacional para aplicações industriais.

Recursos Consultados

Durante o desenvolvimento da solução foram consultados materiais de apoio e documentação técnica para compreensão das funcionalidades utilizadas. Destaca-se a documentação oficial da biblioteca OpenCV:

- OpenCV Documentation. Disponível em: <https://docs.opencv.org/>. Acesso em: 29 maio 2026.
- Streamlit Documentation. Disponível em: <https://docs.streamlit.io/>. Acesso em: 31 maio 2026.